

MEDIATEK

MT8676 Hypervisor AI User Manual

Version: 1.0
Release date: 2024-11-13

Use of this document and any information contained therein is subject to the terms and conditions set forth in Exhibit 1. This document is subject to change without notice.

版本记录

版本	日期	作者	描述
1.0	2024-11-13	吴猛	正式版

目录

版本记录 2

目录 3

图片目录 3

表格目录 3

1 AI 4

 1.1 概述 4

 1.1.1 名词解释 4

 1.2 架构/流程概览 4

 1.2.1 APU 虚拟化 4

 1.2.2 AI 架构 5

 1.2.3 NeuroPilot 开发指南 5

 1.3 配置/客制化指南 6

 1.3.1 NeuroPilot Debug 命令说明 6

 1.3.2 APU Trace 工具抓取 Trace 7

 1.4 特定 MediaTek 平台 NPU 支持的算子信息 9

附件一 附加条款 11

图片目录

图 1-1. AI 架构 5

图 1-2. NeuroPilot Online Document 6

图 1-3. APU trace 8

图 1-4. APU 硬件状态 8

图 1-5. APU 频率状态 9

图 1-6. 支持的算子的集合关系 9

表格目录

表 1-1. 名词解释 4

1 AI

1.1 概述

本章节介绍 MT8676 AI/VPU 相关功能。


1.1.1 名词解释

表 1-1. 名词解释

缩略词	名称及释义
AI	Artificial Intelligence 人工智能
MVPU	MediaTek Vision Processing Unit 联发科视觉处理器单元
NeuroPilot	MediaTek’s Ecosystem for AI Development 联发科人工智能生态系统
MDLA	MediaTek Deep Learning Accelerator 联发科深度学习加速器

1.2 架构/流程概览

1.2.1 APU 虚拟化



更好的兼容性：APU 虚拟化后对 User 层使用 NeuroPilot 方式，和单系统保持一致。

1.2.2 AI 架构

NeuroPilot 是一套由 MediaTek 开发的用于构建高效人工智能应用程序的软件工具和 API 套件；也是 MediaTek 人工智能生态系统的核心。NeuroPilot 支持“Edge AI”，即把 AI 放在本地设备上执行，而不是在服务器上远程执行。这可以使得 AI 任务的执行速度更快，同时也可以保护数据和隐私。




图 1-1. AI 架构

目前 MT8676 软件栈如图 1-1 所示，主要包括如下层：

- **CV/NN 应用层：**这一层包含用户编写的用于运行 AI 应用的代码。该层还包括 MediaTek 解释器，它是一个经过 MediaTek-NPU 优化的 Android TensorFlow Lite 解释器；以及 TFLite Shim API，这是一个基于 MediaTek 解释器之上的包装层，旨在简化 API 调用。
- **NN 运行时层：**这一层包含提供神经网络加速的运行库，包括 NNAPI 和 MediaTek 神经元编译器/运行时。
- **Middleware 层：**该层允许对 MediaTek AI 计算核心进行动态控制，并在此提供用于神经网络工作负载的服务质量控制。
- **驱动层：**该层为专用的 MediaTek AI 计算核心提供驱动程序。

1.2.3 NeuroPilot 开发指南

要访问 NeuroPilot 在线文档，客户首先需要申请一个账户。然后，可以使用这个账户访问 MediaTek 在线文档网站，如图 1-2 所示。该网站提供各种开发资料，包括与开发相关的数据、convert 等一些转换工具、SDK、SampleCode，

以及每个 target 对模型 OP 的支持和限制条件等。需要访问在线文档的客户可以联系 CPM，以获得申请过程的帮助。




图 1-2. NeuroPilot Online Document

开通 NeuroPilot 访问权限后: 进入 <https://neuropilot.mediatek.com/> -> Software Development -> 登陆账号 -> 在 “NeuroPilot SDK & Document” 下选择目标 NeuroPilot {version} -> Latest Version NeuroPilot Online Doc -> 2. Getting Started Guide -> 2.2. NeuroPilot Workflow -> 2.2.3.1. Android Development

1.3 配置/客制化指南

1.3.1 NeuroPilot Debug 命令说明

客户如果遇到 apusys error issue，请先打开以下 log 开关，复现问题，再向 MediaTek 提供整机 log 以及在测试机上的 apusys_rv_xfile (用于解码 apusys_log)，log options 和获取路径如下：

```
Enable NNAPI AOSP log      : adb shell "setprop debug.nn.vlog 1"
Enable TFlite log          : adb shell setprop debug.mtk_tflite.vlog true
Enable Execution plan      : adb shell setprop debug.neuron.runtime.ShowExecPlan true
Enable ShowQoSInfo         : adb shell setprop debug.neuron.runtime.ShowQoSInfo true
Enable Kernel Log          : adb shell "echo 15 > /sys/class/misc/apusys/log/klog"
```

Enable uPLog : adb shell "echo 5 > /proc/apusys_logger/log"

Enable User Log : adb shell setprop debug.apusys.loglevel 15

Enable apusys_rv_xfile : adb pull /proc/apusys_rv/apusys_rv_xfile (用于解码 apusys_log)

将这些需要的开关打开之后再重启 service 使其生效:

- adb shell stop neuralnetworks_hal_service_mtk_neuron
- adb shell start neuralnetworks_hal_service_mtk_neuron

1.3.2 APU Trace 工具抓取 Trace

1.3.2.1 使用 Trace Tool 获取路径

APU Systrace 是用于分析和调试 MediaTek 平台上 AI Processing Unit (APU) 基本运算单元 (如 EDMA、MDLA、MVPU) 运行状态的工具, 可以帮助开发者快速分析运行在 APU 上的模型算法的性能和调试问题。

如何获取 APU trace tool: 进入 <https://neuropilot.mediatek.com/> -> Software Development -> 登陆账号 -> 在

“NeuroPilot SDK & Document”下选择目标 NeuroPilot {version} -> Latest Version NeuroPilot Online Doc -> Downloads -> APU Systrace Tool 下载。

1.3.2.2 APU Trace Tool 使用

如何进行 APU trace 录制: 依次执行 02-trace_start_all.bat -> 运行测试程序 -> 02-trace_stop.bat。其中:

- 02-trace_start_all.bat - start to record trace
- 02-trace_stop.bat - stop trace and pull trace files

下面两个脚本运行是可选的, 如果有开启, 最后生成的 system.trace 中会有 apu middleware 和 neuron trace。

- 08-mdw_trace_enable.bat - To get tracing information from apu middleware.
- 08-neuron_rt_trace_enable.bat - To get tracing information from neuron runtime.

最后会生成三个文件, 根据需要选择查看。请使用 <https://ui.perfetto.dev/> 打开 trace.)

- apusys.trace - apusys trace only
- system.trace - system trace only
- combine.trace - apusys + system trace

1.3.2.3 APU Trace 分析示例

通常使用 MediaTek APU Systrace 抓出并解析得到的 trace 文件有以下三个：

- apusys.trace（仅包含 APU 运行期间各个 Device，如 MDLA/MVPU 上 Tasks 的状况和 APU Frequency, DRAM access, TCM access 等信息）
- system.trace（普通 System trace only，包含 CPU 信息和系统中其他 process/threads 信息）
- combine.trace（apusys + system trace）

为了理清当前系统中运行在 APU 上的线程，通常需要通过系统调试和跟踪工具来获取相关信息。以下是一个详细的 SOP，用于识别和调试当前系统中运行在 APU 上的线程。

1. 使用 perfetto UI 打开 apusys.trace 文件，定位到在 MDLA 或 MVPU (主要 AI 运算单元) Core 上运行的 Task 块。可以获取到以下资讯：
 - 对应 Task 执行的推理耗时，可以放大查看其 pid16652 (线程号)，如图 1-3 所示。
 - 对应 Task 是否运行在 SMP 多核并行模式下，若是多核 MDLA 运行，则会有多个相同颜色/pid 的 Tasks，如图 1-4 所示：




图 1-3. APU trace



图 1-4. APU 硬件状态

- 对应 Task 的 DRAM/TCM 占用情况。

- 对应 Task 执行期间的 MDLA/MVPU Cores 运行频率。
- 还可以通过在 MDLA Core 上运行具有相同 pid 的 Tasks，以判断该 AI 算法是否是周期性执行的。




图 1-5. APU 频率状态

1.4 特定 MediaTek 平台 NPU 支持的算子信息




图 1-6. 支持的算子的集合关系

如图 1-6 所示，MediaTek 平台 NPU 支持的算子，集合由小到大分为 3 个层面：

- Pytorch/TensorFlow Ops -> TFLite Ops: 通过使用 mtk_converter tool 将原本的.pt 或 .pb 模型中的 Ops 转为 TFLite Ops。这步映射过程会进行初步的 Ops 过滤，挡住平台 NPU (HW) 不支持的 Ops。关于哪些 Pytorch/TensorFlow

Ops 可以被 converter 工具识别并转为 Tflite Ops, 可以参考 Online Document: Developer Tools -> Model Development -> Converter -> Converter Tool Supported Operators。

- TFLite Ops -> NPU HW (MDLA/MVPU) Operations: 通过使用 neuronsdk 中的 ncc-tflite (compiler) 将转出的 TFLite 模型编译为 dla 文件。这一步映射过程中会参考 NPU HW (MDLA/MVPU) Operations Guidelines 中的 Specification (Restrictions) 来检查 TFLite 中每个 Op 的详细参数。关于哪些 TFLite Ops 可以被 ncc-tflite 工具识别并编译为 dla 文件, 可以参考: Supported Operations。
- NPU HW (MDLA/MVPU) Operations: 真正可以运行在 NPU (MDLA 或 MVPU) 上的 Ops。

附件一 附加条款

您(或您所代表的公司或其他法律主体, 以下合称「您」)是否得取得、下载与使用本文件及其相关信息皆应以您接受本附加条款为先决要件。您对于本文件之使用、取得或下载即表示您已接受本附加条款并同意受本附加条款之拘束。若您不同意受本附加条款之拘束, 您将不得使用、取得或下载本文件并应立即删除或毁弃所有本文件之副本。

本文件含有联发科技股份有限公司及其关联公司(以下合称「联发科技」)或其授权人之机密信息及专有信息, 仅供您为本文件所描述之联发科技芯片组作内部使用而不得用于其他任何目的(包括但不限于确认或提供支持任何对联发科技、其供货商及/或其直接或间接客户所提潜在专利侵权主张的证据)。禁止未经授权使用或揭露本文件及其中所含信息。您同意赔偿联发科技因您未经授权使用或揭露本文件及其中所含信息之一部或全部导致联发科技所受之任何损失或损害。

联发科技及其授权人保有本文件的所有权及组成所有权之各项权利且未针对任何知识产权授权(无论明示或默示、透过禁反言原则或其他方式)。联发科技得随时变更本文件内容而无须另行通知。联发科技无须承担与使用或信赖本文件相关或因使用或信赖本文件致生之任何责任, 包括但不限于间接损害或附带损害赔偿責任。

本文件及联发科技所提供关于本文件之任何其他材料、信息或技术支持, 均以现况交付为准, 联发科技不负任何明示、默示、法定或其他形式之担保责任, 特别是适销性、不侵权、针对特定用途之适用性、完整性或正确性之担保责任或任何由贸易惯例或交易、履行过程所生之担保责任。对于联发科技为符合您所提规格或遵循特定标准或标准组织的要求所作之交付物, 联发科技亦不应承担任何责任。

于未对前述条款造成限制之情形下, 联发科技不对其产品任何特定用途之适用性承担任何保证或担保责任, 亦不承担任何因产品、电路或软件之应用或使用致生之赔偿责任。您同意您应单独承担关于整合您的产品与联发科技产品所涉及之设计、验证与测试之所有责任, 并确保前述整合产品符合相关标准及任何安全性要求或其他要件。

本附加条款及所有与本附加条款或本文件相关之行为应以台湾法律管辖、解释与阐明, 不适用冲突法原则。